Introduction to Artificial Intelligence - 2023 Summer

Aug 10, 2023 Thu 4 PM

Kwangwoon University MI:RU Artificial Intelligence Study In this course, you will learn

Part 1 – Introduction to Time Series Analysis

Part 2 – Time Series Components and Patterns

Part 3 – Time Series Modeling: ARIMA

Part 4 – Time Series Modeling: Seasonal ARIMA

Part 5 – Time Series Modeling: Exponential Smoothing

Part 6 – Time Series Modeling: ARIMA vs. Exponential Smoothing





Definition and characteristics of time series

#### time series data?

-> 일정한 시간 동안 수집된 일련의 순차적으로 정해진 데이터 셋의 집합

#### characteristics?

-> 시간에 관해 순서가 매겨져 있고, 연속된 관측치는 서로 상관관계를 가짐



# Applications of time series analysis in various domains






Challenges and considerations in analyzing time series data

# Challenges?

- -> 시계열 모형은 여러 변수를 고려할 수 없음
- -> 오차를 피할 수 없음

#### considerations?

-> 특성에서 알 수 있었듯, 관측치가 항상 독립적인 것은 아님(상관관계)





Trend, seasonality, and cyclicity in time series data

#### Trend?

->데이터가 장기적으로 증가하거나 감소할 경우 추세가 존재함.

# 추세의 방향이 변화하는 모습









Trend, seasonality, and cyclicity in time series data

# seasonality?

-> 계절성 요일이 시계열에 영향을 줄 때, 계절성 패턴이 나타남.

# 시계열 데이터에서 계절성을 추출한 모습








Trend, seasonality, and cyclicity in time series data


# cyclicity?

- ->고정된 빈도가 아닌 형태로 증가하거나 감소하는 모습을 주기라고 함
- ->일정하지 않은 빈도로 발생하는 계절성

# 계절성



# 주기성





Stationarity and its importance in time series analysis

# Stationarity? 정상성?

- ->일정하여 늘 한결같은 성질
- ->시간에 무관하게 과거, 현재, 미래의 분포가 같다.
- ->시계열의 평균과 분산이 일정하고, 추세와 계절성이 존재하지 않는 성질

# Why is Stationarity important?

- ->정상성을 가진 데이터는 여러 구간에 걸친 관찰 값 간의 관계가 일정함
- ->시계열 분석의 모델은 정상화된 시계열을 가정함




Autocorrelation and partial autocorrelation functions


#### Autocorrelation?

- ->시계열의 시차 값 사이의 연관 정도
- ->과거의 관찰 값이 현재 관찰 값에 미치는 영향을 확인할 수 있음
- ->ACF(AutoCorrelation Function)을 통해 시각화

# 정상성



#### 비정상성






Autocorrelation and partial autocorrelation functions

#### Partial autocorrelation?

- ->시계열의 시차 값 사이의 순수한 상호 연관성
- ->중간 관측 값과의 연관성은 무시하고 순수한 시차 값 사이의 연관성
- ->PACF(Partial AutoCorrelation Function)을 통해 시각화



Identifying and understanding different patterns in time series data





Introduction to Autoregressive Integrated Moving Average (ARIMA) models

#### ARIMA model?

- ->시계열을 예측하는 방법 중 가장 널리 사용하는 방식
- ->데이터에 나타나는 자기상관을 표현하는데 목적이 있음
- ->현재 값을 과거 값과 과거 예측 오차를 통해 설명함

Differencing for achieving stationarity

How to make stationarity?

- ->정상성을 나타내기 위해 연이은 관측 값들의 차이를 계산할 수 있음
- ->이 방법을 differencing(차분)이라고 함.

# differencing?

-> 이어진 데이터들의 차이를 구하는 것

$$y_t^* = y_t - y_{t-1}$$

Identification, estimation, and interpretation of AR, MA, and I components

# AR(Auto Regressive)?

- -> 과거가 미래를 예측한다는 사실에 기반
- -> AR의 차수는 얼마나 먼 과거의 데이터까지 고려

$$X(t) = w*X(t-1) + b + u*e(t)$$

Identification, estimation, and interpretation of AR, MA, and I components

# MA(Moving Average)?


- ->평균을 중심으로 각 시계열 값이 가지는 오차를 반영
- ->MA(q)의 차수는 얼마나 먼 과거의 오차까지 고려

$$X(t) = w^*e(t-1) + b + u^*e(t)$$

Identification, estimation, and interpretation of AR, MA, and I components


ARIMA(Auto Regressive Integrated Moving Average)?

- -> AR(p) + I + MA(q)
- -> I는 차분에 대한 정보
- -> ARIMA(p,d,q)





1차 차분 2차 차분















Model	ACF	Partial ACF
MA(q)	Cut off after lag q (q시차 이후 0으로 절단)	Die out   (지수적으로 감소,   소멸하는 sine함수 형태)
AR(p)	Die out   (지수적으로 감소,   소멸하는 sine함수 형태)	Cut off after lag p (p시차 이후 0으로 절단)
ARMA(p, q)	Die out (시차 ( <i>q-p</i> )이후 부터 소멸)	Die out (시차 ( <i>q-p</i> )이후 부터 소멸)
















Introduction to Seasonal ARIMA (SARIMA) models

SARIMA(Seasonal Auto Regressive Integrated Moving Average)?


- ->계절성 데이터를 모델링 하기위한 ARIMA 모델
- ->m은 매년 관측 값의 개수























Forecasting with SARIMA models

ARIMA(3,0,1)(0,1,2)로 얻은 예측값

